

온라인 데이터 가이드

데이터 출처·구축 과정 및 변수 설명

본문 1-5부와 온라인 부록 A·B의 실습 데이터 안내

통통한 데이터 분석

서울대학교 과학데이터혁신연구소 · 통계학과

0. 데이터 파일 사용 안내

모든 실습 데이터는 책의 루트 폴더 아래 데이터/에 하위 폴더 없이 둔다. part1.R~part5.R, 온라인부록A_파이썬.ipynb, 온라인부록B_R.Rmd는 책의 루트 폴더에서 실행한다. 데이터 파일은 UTF-8 CSV로 통일했으며, 코드에서는 데이터/파일명.csv와 같은 상대경로를 사용한다.

이 가이드는 최종 배포 파일의 출처, 원자료의 수집 범위, 책에 맞게 구축한 기준, 실제 분석에 남긴 변수와 본문 사용처를 설명한다. 원자료 제공 기관의 이용 조건과 출처 표기 기준은 자료를 내려받거나 재사용하는 시점의 최신 안내를 따른다.

[표 0-1] 최종 데이터 파일 목록

파일	행×열	사용	용도
movie_data.csv	695×8	1부	영화 흥행·배급·국적 분석
seoul_cultural_events.csv	5,366×3	1부	자치구별 문화행사 집계
seoul_apartment_transactions.csv	63,305×6	1부	거래 단위 가격·면적 탐색
reliever_data.csv	481×4	2·4부	구원투수 연봉 회귀·추론
hn19.csv	8,110×9	3·4부	건강 분류와 통계적 추론
boston_marathon_2023.csv	26,598×3	4부	표집과 신뢰구간
seoul_apartment_dong_model.csv	268×9	5부	법정동 단위 변수선택·정규화
seoul_subway_hourly_2024.csv	199,410×26	5부	시간대별 승하차 PCA
k_corporation_reward_survey.csv	510×12	5부	보상 인식 요인분석
mtcars.csv	32×12	5부	자동차 군집분석

1. 1 부 데이터

1.1 movie_data.csv

영화진흥위원회(KOFIC)가 운영하는 영화관입장권통합전산망(KOBIS, <https://www.kobis.or.kr>)에서 제공하는 박스오피스 통계다. 이 시스템은 전국 영화관의 입장권 발권 정보를 실시간으로 집계하는 공식 통계 인프라로, 「영화 및 비디오물의 진흥에 관한 법률」 제39조에 근거해 운영된다. 영화관에서 입장권이 발권될 때마다 자료가 통합전산망으로 전송되며, 집계값은 관계 기관의 검증과 정정 절차를 거친다. 본 책에서는 KOBIS의 기간별 박스오피스 통계 페이지에서 내려받은 자료를 사용했다.

원자료는 1960년부터 2024년까지의 영화를 매출액 기준으로 정리한 자료이며, 최종 파일은 본문 실습에 필요한 695편과 8개 변수만 남겼다. 대표국적·최근 5년 개봉 여부 같은 범주형 변수와 매출액·관객수·스크린수 같은 연속형 변수가 함께 있어, 1부의 분포 시각화, 변수 간 관계 탐색, 자료 변환과 패킷 실습에 사용한다. 배급사가 여러 곳이면 쉼표로 연결되어 있으므로 대표배급사 분석에서는 첫 번째 배급사를 분리해 사용한다.

[표 1-1] movie_data.csv 변수 설명

변수명	자료형	설명	비고
영화명	문자열	영화 제목	-
매출액	정수형	누적 매출액	원
관객수	정수형	누적 관객 수	명
스크린수	정수형	상영 스크린 수	개
대표국적	범주형	대표 제작 국가	-
배급사	문자열	배급사	복수일 때 쉼표 구분
개봉년도	정수형	개봉 연도	1960~2024
5년내개봉작	범주형	최근 5년 내 개봉 여부	Y/N

1.2 seoul_cultural_events.csv

원자료는 서울열린데이터광장에서 공개하는 서울시 문화행사 정보 자료다. 공연·전시·축제·교육·체험

등 서울시와 관련 기관이 등록한 문화행사를 행사 단위로 모은 자료에서, 1부의 자치구별 결합과 집계 실습에 필요한 분류, 자치구, 공연·행사명만 선택했다. 최종 파일은 5,366개 행사로 구성되며, 자치구가 비어 있거나 여러 지역에 걸친 행사가 있을 수 있으므로 집계할 때 결측 범주를 어떻게 처리할지 확인해야 한다.

[표 1-2] seoul_cultural_events.csv 변수 설명

변수명	자료형	설명	비고
분류	범주형	문화행사 분류	공연·전시·축제 등
자치구	문자열	행사 개최 자치구	일부 결측 가능
공연/행사명	문자열	공연 또는 행사 이름	-

1.3 seoul_apr_transactions.csv

서울부동산정보광장과 서울열린데이터광장에서 제공되는 서울시 부동산 실거래 자료를 바탕으로 구축했다. 한 행은 한 건의 거래를 나타내며, 본문에서 가격·면적 분포와 건물용도별 관계를 살피는 데 필요한 6개 변수만 남겼다. 거래금액은 원자료의 만 원 단위를 유지했고, 건물면적과 토지면적은 제곱미터 단위다. 5부의 seoul_apr_dong_model.csv는 여러 출처를 법정동 단위로 집계한 모형용 자료이므로, 거래 단위인 이 파일과는 분석 단위가 다르다.

[표 1-3] seoul_apr_transactions.csv 변수 설명

변수명	자료형	설명	비고
자치구명	문자열	거래 소재 자치구	-
물건금액(만원)	정수형	실거래 금액	만 원
건물면적(m²)	실수형	건물 면적	m²
토지면적(m²)	실수형	토지 면적	m²
건축년도	정수형	건축 연도	일부 결측 가능
건물용도	범주형	아파트·오피스텔 등 건물 유형	-

2. 2 부·4 부 프로야구 데이터

2.1 reliever_data.csv

원자료는 KBO 공식 홈페이지에서 제공되는 기록을 수집하여 가공했다. 국내 프로야구팀 소속 비FA 불펜 투수의 2020~2024시즌 성적과 다음 시즌인 2021~2025시즌 연봉을 연결했다. 외국인 선수와 비FA 다년계약을 체결한 선수는 제외했으며, 동일한 선수의 여러 시즌 기록이 각각 하나의 관측값으로 포함된다. 최종 표본은 481개 관측값이다.

야구에서는 선발 투수가 불펜으로 등판하거나 중간 계투가 대체 선발로 등판할 수 있어 역할 구분이 모호하다. 따라서 해당 시즌 출전 경기 중 절반 이상을 선발로 등판한 경우 선발 투수로 정의하고, 그렇지 않은 경우만 불펜 투수로 포함했다. 평균자책점은 투구 이닝이 적으면 변동성이 크므로 해당 시즌 20이닝 이상을 던진 선수만 남겼다. 마무리 투수는 각 팀에서 세이브 수 상위 2위 이내(동순위 포함)이면서 시즌 세이브가 2회 이상인 경우로 정의했다.

최종 파일은 2부와 4부에서 공통으로 사용하는 네 변수만 남겼다. 선수 이름과 팀·연도는 분석에 사용하지 않아 제외했다. log_salary는 다음 시즌 연봉에 자연로그를 취한 값이다.

[표 2-1] reliever_data.csv 변수 설명

변수명	자료형	설명	비고
ERA	실수형	해당 시즌 평균자책점	20이닝 이상 투수
G	정수형	해당 시즌 출전 경기 수	-
closer	범주형	마무리 투수 여부	1=마무리, 0=중간 계투
log_salary	실수형	다음 시즌 계약 연봉의 자연로그	변환 전 단위: 만 원

3. 3 부·4 부 국민건강영양조사 데이터

3.1 hn19.csv

질병관리청(KDCA)이 운영하는 국민건강영양조사(Korea National Health and Nutrition Examination Survey, KNHANES)는 「국민건강증진법」 제16조에 근거해 1998년부터 매년 실시되는 전국 단위 건강·영양 조사다. 매년 약 1만 명의 표본을 추출하여 검진·건강설문·영양조사를 수행하고, 신체계측, 혈압·혈액 검사, 구강·시력 검사, 식품 섭취 조사 등을 수집한다. 조사 종료 후 가중치 보정과 결측·이상치 검토를 거쳐 원시자료가 공개되며, 보통 자료 수집부터 공개까지 약 12~18개월이 걸린다. 자료실은 <https://knhanes.kdca.go.kr>이며, 회원가입과 사용 목적·출처 표기 약정 후 이용할 수 있다.

이 파일은 제8기 1차년도(2019) 원시자료의 8,110명에 대해 3부 분류 실습의 검진 변수와 4부 추론 실습의 건강설문·영양·소득 변수를 같은 행 순서로 결합한 것이다. 한 행은 한 명의 응답자다. age는 만 80세 이상을 모두 80으로 표시하는 상한 절단이 적용되어 있으며, 이는 개인 식별 위험을 줄이기 위한 공개자료 처리 방식이다.

HE_BMI, HE_HP, HE_DM_HbA1c에는 결측값이 적지 않다. 특히 혈압·혈액 검사는 일부 미성년자에게 시행되지 않아 결측이 발생한다. 분석에서는 사용하는 변수 중 하나라도 결측이면 제외하는 완전 사례 분석과, 필요한 변수의 결측만 제외하는 방식을 목적에 따라 구분한다. HE_DM_HbA1c와 HE_HP는 원래 세 범주를 그대로 쓰거나 정상과 위험군으로 재범주화해 사용한다.

공개 원시자료에는 이름·주민등록번호 같은 직접 식별자가 없고, 세부 거주 정보도 마스킹되어 있다. 그러나 연구·교육 목적과 출처 표기 등 원자료 이용 조건은 그대로 적용된다.

[표 3-1] hn19.csv 변수 설명

변수명	자료형	설명	비고
age	정수형	만 나이	80은 80세 이상
HE_BMI	실수형	체질량지수	kg/m ²
HE_HP	범주형	혈압 상태	1=정상, 2=전 단계, 3=고혈압
HE_DM_HbA1c	범주형	HbA1c 기준 당뇨 상태	1=정상, 2=전 단계, 3=당뇨
sex	범주형	성별	1=남자, 2=여자

변수명	자료형	설명	비고
D_1_1	범주형	주관적 건강 인지	1=매우 좋음~5=매우 나쁨, 9=무응답
live_t	범주형	주택 형태	1=단독, 2=아파트, 3=연립·다세대, 4=기타
N_EN	실수형	1일 에너지 섭취량	kcal
ho_incm5	범주형	가구소득 5분위	1=하~5=상

4. 4 부 보스턴 마라톤 데이터

4.1 boston_marathon_2023.csv

원자료는 SCORE Sports Data Repository¹가 제공하는 2023년 보스턴 마라톤 결과다. 각 행은 대회를 완주한 한 명의 참가자에 해당하며, 원자료는 26,598개 관측값과 연령대, 순위, 배번, 이름, 소속팀, 하프 통과 기록, 넷타임·건타임 등 15개 변수를 포함한다.

4부의 모집단·표집·신뢰구간 실습에서는 40~44세 여성 완주자의 넷타임을 사용한다. 이에 따라 최종 파일에는 연령대, 성별, 분 단위 넷타임만 남겼다. 분석에 쓰지 않는 이름·배번·팀·순위 변수는 제외했다. finish_net_minutes는 출발선을 통과한 시점부터 결승선까지의 넷타임을 초 단위 값에서 분으로 변환한 변수다.

[표 4-1] boston_marathon_2023.csv 변수 설명

변수명	자료형	설명	비고
age_group	문자열	참가자 연령대	18-39, 40-44, ..., 80+
gender	범주형	참가자 성별	M/W
finish_net_minutes	실수형	넷타임 기준 완주시간	분

¹ https://data.scorenetwork.org/running/boston_marathon_2023.html

5. 5 부 데이터

5.1 seoul_apt_dong_model.csv

서울부동산정보광장과 서울열린데이터광장에서 제공되는 여러 자료에서 필요한 변수를 추출·가공하여 구축했다. 자료별 제공 연도가 서로 달라 각 변수의 기준 연도를 함께 확인해야 하며, 모든 변수는 법정동 단위로 평균 또는 비율을 계산했다. 주민등록연앙인구와 국민기초생활보장 수급자 자료는 행정동 단위로 제공되므로 행정동-법정동 대응 관계에 맞춰 변환한 뒤 결합했다.

한 행은 한 법정동이며 총 268개 관측값이다. 1부의 거래 단위 자료와 달리 변수선택과 정규화 실습을 위한 집계·모형용 데이터다. 원자료의 주소 식별 열은 제외했고, 국민기초생활보장 수급자 비율은 백분율이 아니라 0~1 범위로 통일했다.

[표 5-1] seoul_apt_dong_model.csv 변수 설명

변수명	자료형	설명	비고
y	실수형	m ² 당 평균 아파트 매매가격의 자연로그	2021~2023, 변환 전 단위 원
avg_apt_age	실수형	평균 아파트 연식	2023-건축년도
avg_TF_large	실수형	1,000세대 이상 대단지 관련 평균 지표	2023
cnt	정수형	법정동별 아파트 수	2023
rate_big_area_m2	실수형	85m ² 이상 대형 면적 비율	2023
pop_50_69	정수형	50~69세 주민등록연앙인구	2022
rate_buy	실수형	전체 임대·매매 거래 중 매매 비율	2021~2022
rate_welfare_recipient	실수형	연앙인구 대비 기초생활보장 수급자 비율	2022, 0~1
avg_D_Sub	실수형	인근 지하철역까지 평균 거리	2015, m

5.2 seoul_subway_hourly_2024.csv

원자료는 서울열린데이터광장에서 제공하는 서울교통공사의 공개 자료다. 2024년 1월 1일부터 12월

31일까지 서울시 관할 1~8호선의 각 역에서 승차 인원과 하차 인원을 한 시간 단위로 집계했다. 하나의 관측치는 특정 역·날짜·승하차 구분에 대한 20차원의 시간대별 인원 벡터다. 최종 파일은 199,410개 관측값과 26개 변수로 구성된다.

주성분분석 실습에서는 구분이 승차인 관측치만 추출하여 99,705개 관측값을 사용한다. 시간대별 20개 인원 변수의 규모 차이가 분석을 지배하지 않도록 평균 0, 표준편차 1로 표준화한다. 날짜에서 요일과 평일·주말 변수를 만들어 주성분 점수의 패턴을 해석한다.

[표 5-2] seoul_subway_hourly_2024.csv 변수 설명

변수명	자료형	설명	비고
연번	정수형	원자료 행 번호	-
날짜	날짜형	집계 날짜	2024-01-01~2024-12-31
호선	문자열	지하철 호선	1~8호선
역번호	정수형	역 고유 번호	-
역명	문자열	지하철역 이름	-
구분	범주형	승차 또는 하차	승차/하차
06시 이전	정수형	06시 이전 시간대 인원 수	명
06시-07시	정수형	06시-07시 시간대 인원 수	명
07시-08시	정수형	07시-08시 시간대 인원 수	명
08시-09시	정수형	08시-09시 시간대 인원 수	명
09시-10시	정수형	09시-10시 시간대 인원 수	명
10시-11시	정수형	10시-11시 시간대 인원 수	명
11시-12시	정수형	11시-12시 시간대 인원 수	명
12시-13시	정수형	12시-13시 시간대 인원 수	명
13시-14시	정수형	13시-14시 시간대 인원 수	명
14시-15시	정수형	14시-15시 시간대 인원 수	명

변수명	자료형	설명	비고
15시-16시	정수형	15시-16시 시간대 인원 수	명
16시-17시	정수형	16시-17시 시간대 인원 수	명
17시-18시	정수형	17시-18시 시간대 인원 수	명
18시-19시	정수형	18시-19시 시간대 인원 수	명
19시-20시	정수형	19시-20시 시간대 인원 수	명
20시-21시	정수형	20시-21시 시간대 인원 수	명
21시-22시	정수형	21시-22시 시간대 인원 수	명
22시-23시	정수형	22시-23시 시간대 인원 수	명
23시-24시	정수형	23시-24시 시간대 인원 수	명
24시 이후	정수형	24시 이후 시간대 인원 수	명

5.3 k_corporation_reward_survey.csv

K공기업 재직 임직원을 대상으로 선호 보상방식이 직무성과에 미치는 영향을 분석하기 위해 수집한 설문조사 자료다. 전체 원자료는 510명의 응답으로 구성되며 결측값이 없다. 각 보상 문항은 1점(전혀 중요하지 않다)부터 5점(매우 중요하다)까지의 리커트 척도로 측정했다.

원자료에는 직무성과 7문항과 그 평균, 인구통계 6개 변수, 선호 보상방식 12문항이 포함되어 있었다. 5부의 요인분석에서는 보상방식 12문항만 사용하므로 최종 CSV에는 이 변수들만 남겼다. 이론적으로 pay, welfare, training, position, work는 외재적 보상, achievement, responsibility, interest, pride, recognition은 내재적 보상, bonding, promotion은 복합적 보상으로 구분한다. 분석 전에는 문항별 분산 차이를 줄이기 위해 표준화한다.

[표 5-3] k_corporation_reward_survey.csv 변수 설명

변수명	자료형	설명	비고
pay	실수형	금전적 보수 중요도	외재적 보상
welfare	실수형	금전적 복리후생 중요도	외재적 보상

변수명	자료형	설명	비고
training	실수형	교육훈련 기회 중요도	외재적 보상
position	실수형	원하는 보직·인사이드 중요도	외재적 보상
work	실수형	유연근무·휴가 등 근무여건 중요도	외재적 보상
achievement	실수형	직무 성취감 중요도	내재적 보상
responsibility	실수형	직무 책임감 중요도	내재적 보상
interest	실수형	직무 흥미성 중요도	내재적 보상
pride	실수형	조직 자부심 중요도	내재적 보상
recognition	실수형	조직 내 인정 중요도	내재적 보상
bonding	실수형	조직 내 유대감 중요도	복합적 보상
promotion	실수형	승진 중요도	복합적 보상

5.4 mtcars.csv

원자료는 R의 대표적인 내장 데이터셋 mtcars로, 1974년 미국 자동차 전문지 Motor Trend에 수록된 32개 자동차 모델의 기술 제원과 성능 측정값을 담고 있다. 32개 관측값과 11개 수치형 변수로 구성되며 결측값은 없다. R과 파이썬 실습에서 같은 경로 규칙을 쓰도록 자동차 모델명을 model 열로 옮겨 CSV로 제공한다.

계층군집화에서는 model을 제외한 11개 수치형 변수 전체를 사용한다. 변수마다 단위와 분산이 다르므로 평균 0, 분산 1로 표준화한 뒤 거리행렬을 계산한다. vs와 am은 범주형 의미를 가지지만 0/1 수치로 기록되어 있어 다른 변수들과 함께 표준화한다.

[표 5-4] mtcars.csv 변수 설명

변수명	자료형	설명	비고
model	문자열	자동차 모델명	분석 변수에서 제외
mpg	실수형	연비	miles/gallon
cyl	정수형	실린더 수	4-6-8
disp	실수형	배기량	cu.in.
hp	정수형	마력	hp
drat	실수형	후륜 기어비	-
wt	실수형	차량 무게	1,000 lbs
qsec	실수형	1/4마일 주파 시간	초
vs	정수형	엔진 형태	0=V형, 1=직렬
am	정수형	변속기 종류	0=자동, 1=수동
gear	정수형	전진 기어 수	3-4-5
carb	정수형	카뷰레터 수	1-2-3-4-6-8